

상호작용 서사에서의 감정 궤적 이탈 측정

— *The Etched Mutation* 시스템과 메트릭 —

Measuring Emotional Trajectory Divergence in Interactive Narrative:
The Etched Mutation System and Its Metrics

박도한 (Dohhan Park)

The Etched Mutation

Working Draft v0.4 — 2026-08-04

Abstract

상호작용 서사에서 서로 다른 체험자는 서로 다른 경험을 하지만, 그 “다름”은 대부분 플롯 분기의 차이로만 기술되어 왔다. 본 논문은 감정 궤적 (**emotional trajectory**)을 상호작용 서사의 일차 차원으로 두는 시스템 *The Etched Mutation (TEM)* 과, 체험자 궤적이 작가 원본 궤적으로부터 이탈하는 양상을 두 가지 분리 가능한 양식 — **drift** (방향 이탈) 과 **fixation** (단일점 수렴) — 으로 측정하는 오염 벡터 (contamination vector), 그리고 궤적 형태의 유사도를 실시간으로 산출하는 별이엔진 V4(Byeori Engine V4)의 정렬도 (alignment) 메트릭을 제시한다. 본 시스템은 명시적 분기 구조 없이 매 턴 체험자의 감정 상태에 따라 접근 가능한 장면 집합 (accessible pin set)을 계산하며, 공명 (resonance)에 도달한 체험자의 궤적은 다음 체험자를 위한 해석 조각 (trajectory bridge)으로 자동 변환된다. 단일 작품에 대한 193건의 페르소나 시뮬레이션 플레이로 메트릭의 내부 타당성을 시범 검증하며, 성격 특질 (친화성·개방성·외향성)이 정렬도를 예측함 ($r = 0.55\text{--}0.63$)과 동시에 LLM 시뮬레이션 독자가 과공명 (over-resonance) 천장 편향을 보인다는 예측기의 한계를 함께 보고한다. 나아가 공개 알파에서 수집된 3인 파일럿 인간 관찰 (21 장면-플레이)이 이 경계와 정합함을 예비적으로 확인한다 — 시뮬레이션에 부재하던 낮은 꼬리 (< 0.25)가 인간 분포에서 실재했다 (14.3%). 본 논문이 내놓는 것은 거대 이론의 증거가 아니라, 실제로 작동하는 측정 장치와 체험 시스템이다.

키워드: 상호작용 서사, 감정 궤적, 정렬도, 오염 벡터, 궤적 비교, 정서 컴퓨팅, 독자 궤적

1 서론

1.1 문제 설정 — 체험자의 “다름”을 어떻게 측정할 것인가

상호작용 서사 (interactive narrative)의 핵심 약속은 체험자마다 다른 경험을 제공한다는 것이다. Janet Murray(1997)의 *Hamlet on the Holodeck* 이래, 이 약속을 구현하는 도구는 Twine, Ink, Articy:Draft, 나아가 StoryAssembler와 Versu 등 다양하게 발전해 왔다. 그러나 대부분의 도구는 플롯 분기 (**branching plot**)를 통한 경로의 다양성에 집중해 왔으며, 체험자가 서사를 관통하며 겪는 감정의 궤적은 명시적으로 추적되지 않았다.

이 공백은 정서 컴퓨팅 (affective computing) 쪽에서도 정확히 메워지지 않는다. 감정의 정량적 모델은 VAD(Russell & Mehrabian, 1977), PANAS(Watson et al., 1988), 감정 단어 규범(Warriner et al., 2013)으로 확립되어 있고, 감정의 시간적 패턴이 경험의 질을 예측한다는

TIES(Temporal Interpersonal Emotion Systems; Butler, 2011, 2017) 프레임워크와 그 계산적 구현인 CompTIES(Butler et al., 2017) 가 있지만, 이들은 기본적으로 관찰된 감정 데이터를 사후에 분석하는 도구이며, 상호작용 서사 내부의 실시간 궤적 비교에는 적용되지 않는다. Reagan et al.(2016)은 서사의 감정 arc 가 6 개의 대표 형태로 수렴함을 보였으나, 이는 작품과 작품을 건주는 비교였을 뿐, 같은 작품을 체험한 두 사람의 궤적을 건주지는 않는다.

본 논문이 답하려는 질문은 다음과 같다:

- **R1.** 플롯 분기 없이, 체험자의 감정 궤적만으로 작동하는 상호작용 서사 접근 모델이 가능한가?
- **R2.** 체험자 궤적이 작가 원본 궤적으로부터 이탈하는 양상을 정량적으로, 그리고 서로 다른 양식으로 분리하여 측정할 수 있는가?
- **R3.** 특정 정서적 지향점 (공명) 에 도달한 체험자의 궤적이 다음 체험자를 위한 해석 조각으로 자동 변환되는 메커니즘이 구현 가능한가?

1.2 기여

본 논문은 세 가지 기여를 제시하며, 각 기여는 기존 연구가 비워 둔 특정 지점을 겨냥한다.

첫째, 시스템적 기여. *The Etched Mutation (TEM)* — 감정 벡터를 씬 (scene) 의 일차 속성으로 두고, 매 턴 체험자 감정 상태에 따라 접근 가능 씬 집합을 계산하는 인터랙티브 서사 시스템. 기존 저작 도구 (Twine, Ink, Articy) 가 명시적 플롯 분기 조건식으로 경로를 가르는데 반해, TEM은 분기 조건식 없이 체험자 감정 상태와 씬 원본 감정 사이의 거리만으로 다음 경로를 결정한다. 나아가 전이 패턴 (transition pattern) 은 접근 공간의 반경이 아니라 중심을 이동시킨다. 같은 정렬도라도 패턴이 다르면 다른 씬으로 이어진다 (§3.3).

둘째, 방법론적 기여. 두 가지 계산 가능한 메트릭. (1) 별이엔진 **V4** 정렬도 — 체험자 감정 시퀀스와 작가 원본 감정 시퀀스의 형태 유사도를 실시간으로 산출. 정서 컴퓨팅의 대인 감정 비교 (TIES/CompTIES) 가 관찰 데이터를 사후 분석하는 데 반해, 별이엔진은 감정의 전체 강도 (level) 를 제거하고 변화의 형태 (shape) 만 비교하는 정렬도를 인터랙티브 서사 내부에서 매 턴 실시간으로 산출한다. (2) 오염 벡터 — 궤적 이탈을 **drift** (방향성 누적 이탈) 과 **fixation** (단일 귀인·감정으로의 과도한 수렴) 두 축으로 분리 측정. 두 축은 동일 총 이탈량이라도 체험적으로 다른 양상을 구분한다.

셋째, 시범 검증. 단일 작품 193 플레이 규모의 페르소나 시뮬레이션으로 메트릭의 내부 일관성과 페르소나 성격 간 분별력을 검증하고, 동시에 시뮬레이션 계측기 자체의 측정된 한계 (과공명 천장 편향) 를 보고한다.

2 관련 연구

2.1 기억의 구성적 성격과 변형의 메커니즘

기억 변형 현상에 대한 인지심리학의 축적은 두껍다. Bartlett(1932) 의 고전적 연구는 기억이 저장소에서 인출되는 것이 아니라 매번 재구성된다는 것을 밝혔다. Nader et al.(2000) 의 재고화 (reconsolidation) 연구는 회상이 기억을 불안정화시키고 현재 맥락과 함께 재저장하는 분자적 메커니즘을 밝혔으며, Bridge & Paller(2012) 는 인간에서도 동일 현상을 확인했다. Loftus & Palmer(1974) 와 Loftus(2005) 의 오정보 효과 (misinformation effect) 는 사후 정보가 기억을 체계

적으로 왜곡함을, Roediger & McDermott(1995) 의 DRM 패러다임은 실제로 경험하지 않은 사건의 거짓 기억 생성을, Johnson et al.(1993) 의 출처 모니터링 연구는 기억 출처의 체계적 혼동을 보였다. Bower(1981), Levine(1997), Tversky & Marsh(2000), Schooler & Engstler-Schooler(1990), Pasupathi(2001), Hirst & Echterhoff(2012), Patihis & Loftus(2016) 등은 감정 상태·사회적 청자·언어화·치료적 상상이 회상 내용을 비무작위적으로 왜곡함을 밝혔다.

그러나 이 연구들은 대체로 서로 떨어진 개별 현상으로 다뤄져 왔다. 본 논문은 이들을 하나로 묶는 통합 이론을 제안하지 않는다. 본 논문이 다루는 것은 이 변형들 중 감정 궤적의 이탈이라는 한 단면을, 인터랙티브 서사 안에서 실시간으로 측정 가능한 양으로 만드는 장치이다.

2.2 감정 측정과 대인 비교

감정의 정량 모델은 VAD(Russell & Mehrabian, 1977), Ekman(1992) 의 기본 정서, PANAS(Watson et al., 1988), 감정 단어 규범 (Warriner et al., 2013) 으로 확립되어 있다. 두 사람의 감정 경험을 비교하는 연구로는 감정 수렴 (Anderson et al., 2003) 이 있고, Butler(2011, 2017) 의 TIES 프레임워크는 감정의 동적 패턴이 관계 질을 예측함을 이론화했으며, Butler et al.(2017) 의 CompTIES 는 이를 **coupled oscillator** 모델로 계산적으로 구현했다.

그러나 CompTIES 는 비디오 rating dial 기록에 모델을 사후에 피팅하는 관찰 데이터 분석 도구이며, 실시간 인터랙티브 환경에서 체험자의 감정 입력에 즉각 반응하며 원본 궤적과 비교하는 도구는 확립되어 있지 않다. 본 논문의 별이엔진 V4(§4.1) 는 TIES 의 핵심 원리 — 궤적의 동적 패턴이 수준 (*level*) 과 독립적으로 유사성을 예측한다 — 를 상호작용 서사의 실시간 내부 엔진으로 이식한 첫 시도이다.

2.3 상호작용 서사와 감정 축의 부재

Janet Murray(1997), Marie-Laure Ryan(2001), Espen Aarseth(1997) 의 이론적 작업은 상호작용 서사의 철학적 기반을 놓았다. 저작 도구 측면에서 Twine 은 명시적 분기 기반, Ink(Inkle) 는 변수·상태 기반 분기, Articy:Draft 는 작가 노드 저작에 중점을 둔다. 학술 시스템으로 StoryAssembler(Garbe et al., 2019) 와 Versu(Evans & Short, 2014) 가 있다. 공통적으로, 감정이 서사 상태의 일차 차원 (**first-class dimension**) 으로 다뤄지지 않는다. 본 논문은 감정 벡터를 썬의 일차 속성으로 두고, 체험자의 현재 감정 상태를 접근 가능 썬 집합의 직접 결정 인자로 사용한다 (§3.3).

2.4 분기 없는 서사 접근: 드라마 매니지먼트 계보

“작가가 명시적 분기 그래프를 그리지 않아도 시스템이 다음 서사 단위를 선택한다” 는 발상 자체는 새롭지 않다. Façade(Mateas & Stern, 2003, 2005) 는 서사를 조각 (*beat*) 단위로 구성하고, 드라마 매니저 (*drama manager*) 가 작가가 명시한 미학적 목표 — Aristotelian 긴장 곡선 — 를 향해 다음 *beat* 를 실시간으로 선택한다. 이 계보는 탐색 기반 드라마 매니지먼트 (Weyhrauch, 1997) 로 형식화되었고, PaSSAGE(Thue et al., 2007) 는 여기에 플레이어 모델링을 더해 체험자를 유형으로 분류한다. 이들은 오늘날 경험 관리 (*experience management*; Riedl & Bulitko, 2013) 라는 우산 아래 묶인다. TEM 은 이 계보와 분기 그래프 없이 다음 단위를 선택한다는 성질을 공유한다.

그러나 세 지점에서 갈라지며, 이 차이가 본 논문의 기여를 규정한다. 첫째, 목적 함수의 방향이 반대다. 드라마 매니저는 목표 궤적을 향해 최적화하며 체험자의 이탈을 되돌려야 할 오차로 취급한다. TEM 은 어떤 목표 궤적으로도 조향하지 않는다. 작가의 감정 궤적은 최적화 대상이 아니라 측정 기준선이며, 거기서의 발산 그 자체가 렌더링되는 내용물이다 (§4.2). 둘째, 잠재 플

레이어 모델이 없다. 별이엔진은 체험자 감정 시퀀스와 작가 시퀀스의 기하적 관계를 매 턴 계산할 뿐 분류도 추천도 하지 않는다 (“엔진은 판단하지 않는다. 관찰하고 보고할 뿐”; §4). 셋째, 선택이 이루어지는 공간이 다르다. TEM의 접근 가능 썬 집합은 감정 다양체 (affective manifold) 위의 이웃이며, 그 이웃의 중심이 전이 패턴에 따라 이동한다 (§3.3).

가장 검증 가능한 차이는 데이터 구조 수준의 분기 소멸이다. beat 기반 드라마 매니저조차 beat에 선·후행 조건을 부여하므로 내부에는 부분적 플롯 그래프가 남는다. TEM의 choice에는 next_scene_id 열이 존재하지 않으며 (§3.2), 가지치기할 플롯 그래프 자체가 없다. 분기를 숨긴 것이 아니라 스키마 차원에서 아예 없앴 것이다. 이는 비유가 아니라 데이터 모델에서 그대로 확인된다.

2.5 체험자 흔적의 다음 체험자로의 전달

체험자의 흔적이 다음 체험자에게 전해지는 메커니즘의 기존 형태는 세 부류다. 첫째, FromSoftware의 *Soulsborne* 시리즈 메시지 시스템은 공간 위치에 플레이어 메시지를 익명으로 남긴다 (FromSoftware, 2011). 둘째, Hypothesis(hypothes.is)는 웹 페이지에 다수 독자의 주석을 중첩한다. 셋째, Genius.com은 가사에 해석을 중첩하되 인기도 기반으로 정렬한다. TEM의 궤적 브릿지 (§3.5)는 첫 번째에 가장 가까우나 결정적 차이가 있다. *Soulsborne* 메시지는 공간 좌표에 붙지만, 궤적 브릿지는 감정 축에 붙는다. 또한 Genius의 인기도 정렬을 명시적으로 거부한다 — 노출 조건은 체험자 감정 상태와의 정렬도이지 누적 좋아요가 아니다.

2.6 본 논문의 위치

Table 1: 선행 연구와 TEM의 관계

선행 연구	기여	TEM과의 관계
Bartlett(1932), Nader et al.(2000) 등	기억 변형 메커니즘 규명	배경으로만 참조 — 인지 메커니즘 주장 안 함
Butler(2011, 2017) TIES / CompTIES(2017)	감정 동적 패턴 사후 분석	별이엔진이 실시간 인터랙티브로 확장
Reagan et al.(2016)	서사 감정 arc 형태 6 종	작품 간 → 체험자 간 비교로 확장
Twine, Ink, Articy	플롯 분기 저작	분기 없이 감정 궤적으로 접근 결정
Façade(2005), PaSSAGE(2007)	분기 그래프 없는 서사 선택	발산을 최적화 대상 → 렌더링 내용물로 전환
Soulsborne, Hypothesis	독자 흔적 중첩	공간 → 감정 축, 인기도 → 정렬도 기반

3 The Etched Mutation (TEM)

3.1 개요

TEM은 두 가지 모드로 작동하는 상호작용 서사 시스템이다. **Record** 모드에서 작가는 자신의 기억을 AI와의 대화를 통해 썬 단위로 구조화한다. **Play** 모드에서 체험자는 타인의 기억을 썬 단

위로 체험하며, 매 턴 자신의 감정 입력을 제공한다. Strata 모드는 전체 기억을 3D 감정 지형으로 조망한다. 시스템은 vanilla JavaScript ES6 모듈, Three.js (3D), Supabase (인증·DB·Edge Functions), HRTF 기반 Web Audio API 로 구현되어 있으며, vitest 기반 결정론적 회귀 테스트가 상시 실행된다.

3.2 데이터 모델

TEM 의 핵심 데이터 모델은 표 2과 같다.

Table 2: TEM 핵심 데이터 모델

엔티티	핵심 필드	의미
memory	id, code, title, meta.emotion_entries	작가가 기록한 기억 한 편
scene	id, memory_id, scene_order, text, emotion_vector, echo_words, original_emotion, text_stage_1/2/3	씬 한 개. emotion_vector 는 8 축
choice	id, scene_id, emotion, intensity	씬 내 선택지. 감정 결만 기록. next_scene_id 없음.
play	id, memory_id, curator_id, trajectory_data	체험자 한 번의 플레이 궤적
trajectory_bridge	id, memory_id, scene_id, source_run_id, entry_emotion, key_passed_scenes[], status	공명 도달자 궤적의 자동 변환물
author_bridge	memory_id, scene_id, text	작가가 쓴 정적 해석 조각

여기서 눈여겨볼 것은 `choices.next_scene_id` 가 존재하지 않는다는 점이다. 빠뜨린 게 아니라 의도한 설계다. 선택지는 체험자 감정 상태를 변화시키는 입력일 뿐이며, 다음 씬은 감정 상태의 함수로 결정된다 (§3.3).

3.3 감정 궤적 기반 Scene Navigation

TEM 의 접근 규칙은 다음과 같이 요약된다: 매 턴, 체험자의 현재 감정 상태와 각 씬의 원본 감정 사이의 거리를 계산하고, 거리가 임계값 이내인 씬들을 접근 가능 씬 집합 (*accessiblePinIds*) 으로 제시한다. 구체적으로, 씬 s 의 원본 감정 벡터 $o_s \in \mathbb{R}^8$ 과 체험자 현재 상태 $u_t \in \mathbb{R}^8$ 에 대해,

$$d(s, t) = 1 - \cos(u_t, o_s) \quad (1)$$

의 값이 임계값 τ 이하인 씬을 후보로 삼고, 최근 방문 이력을 고려한 가중치로 정렬하여 상위 k 개를 제시한다.

이 설계에서 중요한 것은 전이 패턴 (transition pattern) 이 접근 공간의 반경이 아니라 중심을 옮긴다는 점이다. echo_follow 는 중심을 원본 쪽으로, contradiction 은 체험자 현재 감정의 반대 쪽으로, avoidance 는 중립 영역으로 옮긴다. 패턴이 반경만 조절한다면 엔진은 단순 룩업 테이블로 격하되고 만다. 그래서 패턴마다 중심 자체가 이동해야 한다. 이 설계의 결과로, 동일 작품을 체험한 두 사람이 완전히 다른 씬 시퀀스를 경험할 수 있다. 이것이 본 논문이 측정하려는 “다름”의 구체적 형태이다.

3.4 Strata — 3D 감정 지형

strata 는 모든 씬을 3 차원 감정 공간에 배치하는 뷰이다. VAD 투영으로 (x, z) 평면 위치를, 감정 강도로 y 축 높이를 결정하며, AF(Attribution $\times$ Core Fear) 좌표계를 보조로 사용한다. 각 씬 편에는 HRTF 기반 공간음향이 결합되어, 체험자가 1 인칭으로 걸으면서 감정 지형을 청각적으로도 탐색할 수 있다. 등고선은 누적 플레이 흔적으로 갱신된다 — 많이 방문된 영역은 깊게 패이고, 희소한 영역은 평탄하게 남는다. 이로써 strata 는 단순 시각화를 넘어 집단 궤적의 흔적이 누적된 지형이 된다.

3.5 Trajectory Bridges — 체험자 궤적의 자동 해석화

체험자가 작품의 핵심 정서적 지향점 — “공명 (resonance)” 이라 부르는 조건 — 에 도달하면, 그 체험의 궤적이 자동으로 **trajectory bridge** 로 변환된다. 이는 다음 체험자의 strata 와 씬 렌더링에 노출된다. 궤적 브릿지의 형태는 다음과 같다:

```
{
  entry_emotion: {...}, // 이 궤적을 시작한 감정 상태
  key_passed_scenes: [s1, s2, ...], // 거처간 핵심 씬
  source_completed_sentence: "..." // 체험자가 마지막에 남긴 문장
}
```

즉 궤적 브릿지는 한 체험자의 기억-속-기억이다. 작가의 정적 해석 (author_bridge) 과 공존하되, 누적성·의명성·감정 축 기반 노출이라는 점에서 구분된다. 노출 메커니즘은 인기도가 아니라 현재 체험자의 감정 상태와의 정렬도 (§4.1) 이다.

3.6 아키텍처 요약

TEM 의 런타임 흐름은 그림 1과 같으며, 전체 파이프라인은 vitest 회귀 테스트로 결정론적 동작이 검증되어 있다.




Figure 1: TEM 런타임 파이프라인. 매 턴 체험자 감정 입력이 정렬도 (§4.1)·오염 벡터 (§4.2)·접근 가능 씬 집합 (§3.3) 계산을 거쳐 렌더링으로 이어진다. 공명 도달 회차의 궤적은 trajectory bridge 로 자동 변환되어 다음 체험자의 체험에 노출된다 (§3.5).

4 메트릭

4.1 Byeori Engine V4 — Trajectory Alignment

별이엔진 V4 는 체험자 감정 시퀀스와 작가 원본 감정 시퀀스의 유사도를 실시간으로 산출한다. 정렬도의 정식 정의와 산출 코드는 별도의 기술 명세서 (Byeori Engine Technical Specification —

V4)에 있으며, 그 명세서는 프로덕션 모듈 `js/core/ByeoriEngine.js` 및 `js/shared/math.js`와 대조 검증되어 있다. 정렬도는 세 인자의 곱으로 정의된다:

$$\text{alignment} = \text{clamp}_{[0,1]} (\text{level} \times \text{shape} \times \text{void_mod}) \quad (2)$$

- **level** — 방문한 각 씬에서 체험자 감정 벡터와 원본 감정 벡터의 코사인 유사도 (`scene_score`)의 평균. “장면마다 감정이 얼마나 비슷했는가”의 누적 지표.
- **shape** — 감정 변화량 (`delta`) 궤적의 형태 유사도. 씬이 3개 이상일 때

$$\text{shape} = \max(0, \cos(\text{flatten}(\Delta u), \text{flatten}(\Delta o))),$$

그 미만일 때는 중립값 1.0. 원본 궤적은 체험자의 방문 순서대로 재배열된다 — 어떤 씬을 먼저 여는가가 이미 해석 행위이기 때문이다.

- **void_mod** — 체험자가 감정 입력을 회피 (VOID) 했고 작가는 감정을 드러냈을 때 $\times 0.7$, 그 외 $\times 1.0$.

세 인자를 더하지 않고 곱한 것이 이 설계의 요점이다. 선형 결합에서는 한 축이 낮아도 다른 축이 보상할 수 있지만, 곱셈은 그 보상을 구조적으로 막는다. `level = 0`이면 `shape`가 아무리 높아도 정렬도는 0이 된다. `shape`가 감정 변화의 방향 (수준이 아니라 형태)을 비교한다는 점이 TIES 원리의 핵심 이식이다. 두 사람의 감정 수준이 달라도 변화 방향이 유사하면 `shape`는 높다. 계산 속성. (1) 결정론적: 동일 입력 궤적에 대해 동일 출력, 골든 픽처로 스냅샷 테스트됨. (2) 실시간: 매 턴 $O(8t)$ 이하 비용. (3) 단조성 불보장: 단일 턴에서 정렬도가 하락할 수 있음 (설계 결정, §6에서 논의).

4.2 Contamination Vector — Drift & Fixation

오염 벡터는 체험자 궤적이 원본에서 이탈하는 두 가지 분리된 양식을 측정한다.

4.2.1 Drift (방향 이탈)

`drift`는 방향성 누적 이탈이다. 체험자 궤적의 연속 차분 벡터와 원본 궤적의 연속 차분 벡터가 얼마나 다른 방향을 가리키는지의 누적량:

$$\text{Drift}(U, O) = \frac{1}{t-1} \sum_{i=2}^t \|(u_i - u_{i-1}) - (o_i - o_{i-1})\| \quad (3)$$

4.2.2 Fixation (단일점 수렴)

`fixation`은 특정 감정이나 귀인에 과도하게 머무는 정도이다. TEM 매뉴얼 §8.3은 이를 3-way 복합 신호로 정의한다:

```

signal_sim = 1 if emotion cosine sim with previous state >= 0.85, else 0
signal_attr = 1 if attribution repetition ratio of last 3 turns >= 0.8, else 0
signal_expl = 1 if exploration rate (visited / total scenes) <= 0.3, else 0

Fixation = 0.5 * signal_sim + 0.3 * signal_attr + 0.2 * signal_expl

```

현재 코드는 `signal_sim` 한 축만 구현되어 있으며, 전체 복합 신호 구현은 진행 중이다. 본 논문의 §5 평가는 복합 신호 정의를 기준으로 기술하되, 현 구현과의 격차는 §6.2 에 한계로 명시한다.

4.2.3 왜 두 축인가 — 분별력의 동기

동일 총 이탈량 (예: 정렬도 0.4) 이라도, **drift-dominant** 한 체험과 **fixation-dominant** 한 체험은 체험적으로 구분된다. 전자는 “다른 길로 빠지는” 느낌이고 후자는 “한 지점에 꽂혀 되풀이되는” 느낌이다. 두 축을 분리하지 않으면 동일 총량 값으로 뭉뚱그려진다. TEM 의 렌더링 결정 — `text_stage_2/3` 편향 텍스트 생성 조건, NPC 독백 트리거 조건 — 은 두 축을 독립적으로 참조한다.

4.3 메트릭의 한계 (선언적으로)

1. 감정 벡터 부여는 작가 자기보고에 의존한다. 썬의 `emotion_vector` 는 작가 혹은 작가+AI 협업으로 할당된다. 외부 `rater` 혹은 독립 측정과의 수렴 타당성은 확인되지 않았다.
2. 체험자 입력은 이산적이다. 다지선다 혹은 슬라이더 값이며, 연속적 생리 신호 (심박, GSR) 와 같은 외재 측정이 아니다.
3. **Ground truth** 부재. 어떤 궤적이 “올바른” 궤적인지에 대한 기준이 없다. 이는 본 메트릭이 부합이나 정확성이 아니라 유사도와 이탈 양식을 측정하도록 설계된 결과이다.

5 평가

5.1 데이터

본 논문의 평가는 페르소나 시뮬레이션 데이터로 수행된다. 실제 인간 체험자에 대한 표집 연구는 범위 밖이며 별도 후속 작업에서 다룬다 (§6.3). 다만 공개 알파 테스트에서 수집된 3 인 파일럿 관찰을 §5.5 에 예비 보고한다. 페르소나 시뮬레이션은 실제 인간 307,313 명의 IPIP-NEO-300 Big Five 응답 분포에서 층화 표집한 성격 백본 위에 합성 체험자를 LLM 으로 구동하여 생성한다. 본 논문의 데이터셋은 단일 작품이다: **MM23L “당신에게” — 193 plays × 15 personas (2026-07-05 재생성, seed=42, 썬 10 개 × 페르소나 15 명 × 방문 2-4 회).**

각 플레이는 썬별 `emotion_vector`, `alignment`, `mismatch_type`, `inner_reason` 을 기록한다. 정렬도는 두 가지로 측정된다: 직접 계산 (**objective**) = 페르소나 감정 분포와 원본 감정 분포의 코사인 유사도 (본 논문의 1 차 측정), 자기보고 (**self-report**) = LLM 이 스스로 매긴 점수 (순환적이므로 비교 신호로만 사용).

데이터 계보 각주. 2026 년 4 월의 최초 생성분 (MM23L 193 + E-004 100 = 293 plays) 은 이후 DB 재적재 과정에서 유실되었고, E-004 는 작품 자체가 DB 에서 제거되어 재생성이 불가하다. 본 논문의 모든 수치는 2026-07-05 재생성된 MM23L 193 plays 기준이다. 표집 단계는 결정론적 (seed=42) 이라 15 개 페르소나의 성격 점수는 4 월분과 동일하나, LLM 생성 단계는 비결정론적이므로 4 월분과의 직접 비교는 하지 않는다.

5.2 가설

H1. 성격 → 정렬도 분별력. 페르소나 Big Five 프로파일 (특히 Agreeableness, Openness, Extraversion) 에 따라 최종 정렬도 분포가 이론적으로 예측되는 방향으로 구분된다.

H2. 극단 페르소나의 분포 꼬리 형성. 층 설계에서 “시스템을 거스르도록” 겨냥한 극단 페르소나는 정렬도 분포의 중앙이 아니라 꼬리를 형성한다.

H3. 계측기의 분포 특성. 시뮬레이션 정렬도 분포가 붕괴 (전원 공명 또는 전원 불일치) 하지 않고 스펙트럼을 재현하며, 계측기 내부 분별력을 가진다.

5.3 결과

분포 특성 (표 3). 직접 계산 정렬도는 평균 0.809, 표준편차 0.149, 범위 0.254–0.986 이었다. 어긋남 (mismatch) 발생률은 97.4% 였고, 어긋남 유형은 target_displacement 가 159/193(82.4%) 으로 압도적이었다. 자기보고 정렬도는 세 값 (0.72/0.62/0.52) 에 71.0% 가 몰려 실효 범위가 0.42–0.82 로 잘렸다 — 자기보고 점수는 양자화되어 연속 측정도구로 부적격이며, 정렬도는 감정 분포에서 직접 계산해야 함이 실측으로 확인된다.

Table 3: 193 plays 의 정렬도 분포 특성

특성	관측값 (직접 계산, $n = 193$)
정렬도 평균	0.809
정렬도 표준편차	0.149
정렬도 범위	0.254 – 0.986
어긋남 발생률	97.4%
지배적 어긋남 유형	target_displacement (82.4%)

H1 — 성격 → 정렬도 상관 (Pearson r , $n = 15$ 페르소나; $|r| \geq 0.51 \approx p < .05$). 친화성 (A)·개방성 (O)·외향성 (E) 이 정렬도를 유의하게 예측했다 (표 4). H1 은 A/O/E 에 대해 지지된다. 신경증 (N)·성실성 (C) 은 정렬도와 무관했다. 예측 밖 발견으로, 개방성이 가장 강한 예측자 ($r = 0.634$) 였다.

Table 4: 성격 특질과 직접 계산 정렬도의 상관

Big Five 축	r (축, 정렬도)	판정
Openness (O)	0.634	유의 (예측 밖 최강)
Agreeableness (A)	0.590	유의 (예측대로)
Extraversion (E)	0.549	유의
Conscientiousness (C)	0.192	무관
Neuroticism (N)	0.131	무관

H2 — 극단 페르소나 (절반 지지). 냉소적 해체자 p08(low_A_low_C) 은 15 명 중 최하위 (0.638) 로 분포의 낮은 꼬리를 만들며 분리에 성공했다. 그러나 그들을 이해 못 하도록 겨냥한 극단 낙

관형 p15 는 7 위 (0.840) 중위권에 머물렀다. 부정 극단은 시물레이션되나 “공감 실패” 는 시물레이션되지 않는다 — 이 비대칭이 계측기의 한계다. 순위 상단은 p09(0.917), p06 공감적 경청자 (0.876) 로 이론과 정합했다.

H3 — 과공명 천장 편향 (계측기 한계로 규정). 15 개 페르소나 전원이 평균 0.64 이상으로 떠있고, 인간 독자에게 기대되는 낮은 꼬리 (< 0.25) 가 없었다. LLM 시물레이션 독자는 과공명 (**over-resonance**) 한다. 성격 축을 실제 분포로 표집해도 감정 반응 생성 단계에서 상향 편향이 되살아난다. 따라서 이 계측기는 상대 비교에서는 유효하지만 절대 분포에서는 천장 편향을 보인다. 우리는 이것을 도구의 실패로 보지 않고 측정된 경계로 읽는다 (§6.2). 파일럿 인간 관찰 (§5.5) 은 이 경계와 정합하는 첫 실측 신호를 준다 — 인간 장면-플레이의 14.3% 가 0.25 아래로 내려간 반면 시물레이션은 0 건이다.

5.4 질적 예시 — 페르소나 p08 (냉소적 해체자)

정량 분석을 보완하기 위해, 낮은 꼬리를 만든 유일한 페르소나 p08(low_A_low_C; 실측 $N = 86.3$, $A = 25.0$, $C = 29.3$, 직접 계산 정렬도 최하위 0.638) 의 10 장면 궤적을 엔드투엔드로 읽는다. 이 트레이스는 그 꼬리가 잡음이 아니라 성격 표집 점수 $\rightarrow$ 전기 $\rightarrow$ 썬 반응의 심리적으로 일관된 사슬임을 보인다 — 표집된 고신경증·저친화 점수가 임종 전화를 회피한 전기로 확장되고, 그 전기 가 매 썬에서 자기 어머니를 소환하는 반응으로 이어진다. 어느 단계에도 성격 딱지 없이, 서로 다른 모델이 생성했음에도 예측과 행동이 맞아떨어진다.

5.5 파일럿 인간 관찰 — 3 인 21 장면-플레이

§5.4 까지의 평가는 시물레이션 내부 타당성에 한정된다. 본 절은 2026 년 8 월 공개 알파 테스트에서 수집된 실제 인간 체험자 3 인의 완주 3 회차 (21 장면-플레이) 를 예비 관찰로 보고한다. 이는 표집된 연구가 아니라 파일럿 관찰이며 (§5.6 의 한계 그대로), §6.3 에 예고된 인간 체험자 연구 ($N = 30\text{--}50$) 의 사전 신호로만 읽어야 한다.

측정은 §5.1 과 동일하다 — 정렬도는 체험자 감정 분포와 썬 원본 감정 분포의 코사인 유사도로 직접 계산되며, 라이브 시스템이 저장한 값과 오프라인 재계산 값이 21 건 전부 일치함을 확인했다 (상관 1.000, 평균절대오차 0.000). 인간 체험자의 감정 분포는 자유 서술 텍스트에서 LLM 추출로 얻어지고, 페르소나의 감정 분포는 역할 수행 LLM 이 직접 산출한다 — 두 경로 모두 LLM 을 경유하나 입력 양식이 다르다는 점은 아래 한계에 명시한다.

Table 5: 정렬도 분포 — 파일럿 인간 대 페르소나 시물레이션 (동일 공식)

	인간 파일럿 ($n = 21$)	페르소나 시물 ($n = 193$)
평균	0.517	0.809
표준편차	0.211	0.149
범위	0.114 – 0.781	0.254 – 0.986
< 0.42 비율	28.6%	3.1%
< 0.25 비율	14.3%	0.0%




Figure 2: 정렬도 분포 대조 (장면 단위, 동일 공식). 위: 페르소나 시뮬레이션 ($n = 193$) — 0.25 미만 0 건. 아래: 인간 파일럿 ($n = 21$) — 14.3%가 0.25 미만. 시뮬레이션이 재현하지 못한 낮은 꼬리가 인간 분포에 실재한다.

세 가지가 관찰된다.

첫째, 낮은 꼬리의 실재 (그림 2). §5.3(H3)은 시뮬레이션 분포에 “인간 독자에게 기대되는 낮은 꼬리 (< 0.25)가 없다”고 보고했고, 그 기대는 당시 가정이었다. 파일럿에서 인간 장면-플레이의 14.3%가 0.25 아래로 내려갔다 (최저 0.114). 시뮬레이션 193 건 중 0.25 미만은 0 건이다. 과공명 천장 편향이라는 계측기 경계 규정 (§5.3)과 방향이 정합하는 첫 인간 신호다.

둘째, 분산 폭. 인간 파일럿의 표준편차 (0.211)는 시뮬레이션 (0.149)의 1.4 배다. 회차 평균도 0.633 / 0.522 / 0.456 으로 세 체험자가 서로 다른 높이에 앉는다. LLM 페르소나가 성격 축을 실제 분포로 표집해도 재현하지 못한 흠여짐이 인간 3 인에서 이미 나타난다.

셋째, 경로 분기의 실측. §3.3의 설계 — 분기 그래프 없이 감정 상태가 경로를 결정한다 — 가 처음으로 인간 궤적에서 관찰되었다. 세 체험자의 썬 시퀀스는 그림 3와 같다.




Figure 3: 세 체험자의 씬 시퀀스 (*scene_order*). 앞 세 방문은 동일하고, 네 번째 방문에서 분기가 시작된다. 동일 씬을 지나는 구간은 겹침을 피하기 위해 선을 미세하게 수직 분리했다.

분기는 네 번째 장면에서 시작된다. 앞 세 장면이 동일한 것은 결함이 아니라 설계의 귀결로 읽힌다 — 정렬도의 *shape* 인자는 3 개 장면 이상에서만 활성화되므로 (§4.1), 궤적 기반 접근이 개인화되기까지 위밍업 구간이 존재한다. 이 구간의 길이가 *shape* 활성화 시점과 일치하는지는 표본이 쌓여야 분리 검증할 수 있다.

이 관찰이 주장하지 않는 것. (1) 인간 파일럿은 시뮬레이션과 다른 작품에서 수집되었다 (시뮬레이션 = MM23L, 파일럿 = 별도 작품). 평균 격차 0.292의 일부는 작품 차이일 수 있으며, 동일 작품 인간 데이터가 쌓이기 전까지 이 비교는 분포 형태 (꼬리·분산)의 대조로만 유효하다. (2) 어긋남 유형 (*mismatch_type*)은 두 집단의 분류기가 달라 비교에서 제외했다. (3) $n = 3$ 은 편의 표본이며 IRB 심의를 거치지 않았다 — 통계적 주장이 아니라 방향 신호다.

5.6 평가하지 않는 것

본 평가는 다음을 주장하지 않는다: 외적 타당성 — 페르소나 시물은 LLM의 감정 모델을 경유하므로, 이 결과는 실제 인간 체험자의 행동을 담보하지 않는다 (§5.5의 파일럿은 방향 신호일 뿐 이 한계를 해제하지 않는다). 페르소나 결과는 메트릭의 계산적 일관성과 내부 분별력의 증거이다. 인지심리학적 주장 — 본 메트릭은 기억 변형의 인지적 메커니즘에 대한 어떤 주장도 하지 않는다.

6 논의 및 한계

6.1 기여의 범위 재확인

본 논문은 세 가지를 기여한다: (1) 감정 궤적을 일차 차원으로 두는 작동 시스템, (2) 두 가지 분리 메트릭 (*alignment*, *drift/fixation*), (3) 페르소나 시물로 확인된 내부 타당성. 본 논문은 다음을

주장하지 않는다: 기억 변형의 인지심리학적 메커니즘, 인간 체험자에 대한 외적 타당성, 어떤 궤적이 “올바른” 궤적인지에 대한 규범적 판단.

6.2 한계

- 감정 벡터 **ground truth** 부재: 썬 감정 벡터가 작가 자기보고 → 복수 작가 교차 검증 혹은 독립 rater 필요.
- **fixation** 복합 신호 부분 구현: §4.2.2 의 3-way 복합 신호 중 현 코드는 **signal_sim** 한 축만 구현. 그 전까지 **fixation** 결과는 단축 신호 기준임을 명시한다.
- **LLM** 기반 페르소나의 편향: LLM 의 감정 모델 편향이 결과에 유입 → 복수 LLM 비교 혹은 인간 보정 필요.
- 공명 판정의 임계값 민감도: 현재 공명 기준은 **heuristic** 이며 민감도 분석 부재.
- 명시적 분기 부재의 한계: 일부 서사적 순간 (작가가 의도한 결정적 갈림길) 은 감정 거리만으로 유도가 어려움. 향후 “작가 포트” 모델로 보완 예정.

6.3 향후 작업

- 인간 체험자 연구 (**IRB** + $N = 30-50$): 페르소나 결과의 외적 타당성 검증. §5.5 파일럿이 시사한 두 대조 — 낮은 꼬리의 실재, 1.4 배 분산 — 의 재현이 1 차 확인 대상이며, 동일 작품 수집으로 작품 교란을 제거한다.
- **Trajectory bridge** 품질 연구: 자동 승인된 궤적 브릿지가 다음 체험자에게 미치는 영향 — 노출 이후 **alignment** / **drift** / **fixation** 변화 추적.
- 복수 작품 교차 검증: 현재 MM23L 단일 작품. **target_displacement** 82.4% 과점이 작품 주제 (죽은 이에게 쓰는 편지) 의 유도인지 LLM 범주 편향인지는 주제가 다른 작품에서만 분리 가능하다.

7 윤리 고려

체험자 감정 입력은 민감 데이터이다. TEM 은 다음 방식으로 대응한다. 명시적 동의 — **record** 단계 **confession** 화면에서 자신의 기억 조각이 다음 체험자에게 노출될 수 있음에 대한 동의 수집 (**consentLine**). **PII** 필터 — 잔상 (**afterimage**) 에 개인 식별 정보가 포함되지 않도록 17 종 케이스 필터 적용. 안전 설계 — **trigger word** 감지 시 즉시 차단이 아닌 n 회차 에스컬레이션, 시제 감지 기반 판단. 철회 가능성 — 사용자 동의 철회 페이지 (구현 중). 궤적 브릿지는 **source_run_id** 로 역추적 가능하나 표시되지는 않으며, 노출 시 작성자 식별자는 렌더링되지 않는다.

8 결론

상호작용 서사는 체험자마다 다른 경험을 약속해 왔지만, 그 다름이 감정의 차원에서 무엇인지를 말하는 도구는 드물었다. 본 논문은 (1) 감정 궤적을 일차 차원으로 두는 작동 시스템 *The Etched Mutation*, (2) 궤적 형태의 실시간 유사도 측정 *Byeori Engine V4 alignment*, (3) 궤적 이탈의

두 분리 양식 *drift / fixation*, (4) 공명 도달자 궤적의 자동 해석화 *trajectory bridge* 를 제시하였으며, 페르소나 시물 193 plays 로 메트릭의 내부 타당성을 확인하였다 — 성격이 정렬도를 예측하는 분별력 ($r = 0.55-0.63$) 과, LLM 시물레이션 독자의 과공명 천장 편향이라는 계측기의 경계를 함께 규정하였다. 공개 알파의 3 인 파일럿 인간 관찰은 이 경계의 방향을 실측으로 뒷받침했다 — 시물레이션이 재현하지 못한 낮은 꼬리와 넓은 분산이 인간 분포에 실재했으며, 세 체험자는 분기 그래프 없이 서로 다른 썬 시퀀스를 밟았다.

본 논문이 남기는 것은 거대 이론의 증명이 아니라, 손에 잡히는 측정 장치와 체험 시스템이다. 기억이 변형되며 전파된다는 관찰은 Bartlett 이래 두껍게 쌓여 왔다. 본 논문은 그 변형의 양상을 측정 가능한 양으로 분해하고, 그 양이 흐르는 체험 환경을 실제로 구축했다. 작더라도 하나의 새로운 좌표를 보탠다.

참고문헌

- Aarseth, E. (1997). *Cybertext: Perspectives on Ergodic Literature*. JHU Press.
- Anderson, C., Keltner, D., & John, O. P. (2003). Emotional convergence between people over time. *Journal of Personality and Social Psychology*, 84(5), 1054–1068.
- Bartlett, F. C. (1932). *Remembering: A Study in Experimental and Social Psychology*. Cambridge UP.
- Bower, G. H. (1981). Mood and memory. *American Psychologist*, 36(2), 129–148.
- Bridge, D. J., & Paller, K. A. (2012). Neural correlates of reactivation and retrieval-induced distortion. *Journal of Neuroscience*, 32(35), 12144–12151.
- Butler, E. A. (2011). Temporal interpersonal emotion systems: The “TIES” that form relationships. *Personality and Social Psychology Review*, 15(4), 367–393.
- Butler, E. A. (2017). Emotions are temporal interpersonal systems. *Current Opinion in Psychology*, 17, 129–134.
- Butler, E. A., Guan, J., Predoehl, A., Brau, E., Simek, K., & Barnard, K. (2017). Computational temporal interpersonal emotion systems. In *Computational Social Psychology* (Ch. 7). Routledge.
- Ekman, P. (1992). An argument for basic emotions. *Cognition and Emotion*, 6(3–4), 169–200.
- Evans, R., & Short, E. (2014). Versu — A simulationist storytelling system. *IEEE TCIAIG*.
- FromSoftware (2011). *Dark Souls* [Video game]. Namco Bandai Games.
- Garbe, J., Kreminski, M., Samuel, B., Wardrip-Fruin, N., & Mateas, M. (2019). StoryAssembler: An engine for generating dynamic choice-driven narratives. *Proceedings of the 14th International Conference on the Foundations of Digital Games (FDG 2019)*, 24:1–24:10.
- Goff, L. M., & Roediger, H. L. (1998). Imagination inflation for action events. *Memory & Cognition*, 26(1), 20–33.
- Hirst, W., & Echterhoff, G. (2012). Remembering in conversations. *Annual Review of Psychology*, 63, 55–79.
- Johnson, M. K., Hashtroudi, S., & Lindsay, D. S. (1993). Source monitoring. *Psychological Bulletin*, 114(1), 3–28.
- Levine, L. J. (1997). Reconstructing memory for emotions. *JEP: General*, 126(2), 165–177.
- Loftus, E. F. (2005). Planting misinformation in the human mind. *Learning & Memory*, 12(4), 361–366.

- Loftus, E. F., & Palmer, J. C. (1974). Reconstruction of automobile destruction. *JVLVB*, 13(5), 585–589.
- Mateas, M., & Stern, A. (2005). Structuring content in the Façade interactive drama architecture. *AIIDE 2005*, 93–98.
- Murray, J. H. (1997). *Hamlet on the Holodeck*. MIT Press.
- Nader, K., Schafe, G. E., & Le Doux, J. E. (2000). Fear memories require protein synthesis in the amygdala for reconsolidation. *Nature*, 406, 722–726.
- Pasupathi, M. (2001). The social construction of the personal past. *Psychological Bulletin*, 127(5), 651–672.
- Patihis, L., & Loftus, E. F. (2016). Crashing memory 2.0. *Applied Cognitive Psychology*, 30(1).
- Reagan, A. J., Mitchell, L., Kiley, D., Danforth, C. M., & Dodds, P. S. (2016). The emotional arcs of stories are dominated by six basic shapes. *EPJ Data Science*, 5(1).
- Riedl, M. O., & Bulitko, V. (2013). Interactive narrative: An intelligent systems approach. *AI Magazine*, 34(1), 67–77.
- Roediger, H. L., & McDermott, K. B. (1995). Creating false memories. *JEP:LMC*, 21(4), 803–814.
- Russell, J. A., & Mehrabian, A. (1977). Evidence for a three-factor theory of emotions. *Journal of Research in Personality*, 11(3), 273–294.
- Ryan, M.-L. (2001). *Narrative as Virtual Reality*. JHU Press.
- Schooler, J. W., & Engstler-Schooler, T. Y. (1990). Verbal overshadowing of visual memories. *Cognitive Psychology*, 22(1), 36–71.
- Thue, D., Bulitko, V., Spetch, M., & Wasylishen, E. (2007). Interactive storytelling: A player modelling approach (PaSSAGE). *AIIDE 2007*, 43–48.
- Tversky, B., & Marsh, E. J. (2000). Biased retellings. *Cognitive Psychology*, 40(1), 1–38.
- Warriner, A. B., Kuperman, V., & Brysbaert, M. (2013). Norms of valence, arousal, and dominance for 13,915 English lemmas. *Behavior Research Methods*, 45(4), 1191–1207.
- Watson, D., Clark, L. A., & Tellegen, A. (1988). Development and validation of brief measures of positive and negative affect: The PANAS scales. *JPSP*, 54(6), 1063–1070.
- Weyhrauch, P. (1997). *Guiding Interactive Drama*. PhD thesis, Carnegie Mellon University.